Ouvidoria Semântica — Relatório Técnico

Integrantes: Igor Nunes Moneta; Josenilton Cirne Ramalho Neto; Pedro Henrique Alves Vieira do Nascimento.

1. Visão geral e arquitetura

O projeto implementa um fluxo de recuperação semântica para 40 manifestações cidadãs distribuídas nas categorias infraestrutura, saúde, segurança, educação e meio ambiente. O pipeline normaliza os textos em português, gera embeddings com Sentence Transformers e calcula similaridade de cosseno. A aplicação Streamlit disponibiliza busca semântica, base completa, matriz de similaridade, redução dimensional e chunking.

Fluxo: corpus → limpeza → embeddings → similaridade → busca/duplicatas → PCA ou t-SNE → interface Streamlit.

2. Comparação BoW, TF-IDF e embeddings

A Entrega 1 implementa as três representações e calcula a similaridade dos pares M003×M017, M008×M022 e M008×M031. BoW mede sobreposição direta de termos; TF-IDF pondera termos pela importância na coleção; embeddings representam significado e contexto, sendo mais adequados para paráfrases. Nos pares de duplicatas, a expectativa é que embeddings sejam mais robustos quando as palavras mudam. No par M008×M031, os métodos devem distinguir problemas de saúde de iluminação, embora frases curtas possam produzir sinais espúrios.

3. Detecção de duplicatas

A função detectar_duplicatas(textos, limiar=0.85) compara todos os pares acima da diagonal da matriz de similaridade e retorna aqueles com score igual ou superior ao limiar. O valor 0.85 é usado como ponto inicial conservador. A análise do notebook compara os pares encontrados com seis pares duplicados semânticos presentes no corpus, permitindo contabilizar verdadeiros positivos, falsos positivos e falsos negativos.

4. Chunking

Cinco manifestações possuem mais de 500 caracteres. A Entrega 3 usa RecursiveCharacterTextSplitter e compara (chunk_size=300, overlap=30) com (chunk_size=500, overlap=100). O overlap mantém parte do contexto no chunk seguinte e reduz a ruptura de ideias. Chunks maiores preservam mais contexto; chunks menores oferecem maior granularidade. A análise também gera embeddings dos chunks e os projeta em PCA para verificar visualmente se unidades da mesma manifestação permanecem próximas.

5. Aplicação Streamlit

O arquivo app_ouvidoria.py possui quatro abas: Busca Semântica, Base Completa, Espaço Vetorial e Chunking. Na busca, o cidadão informa uma descrição e recebe os top-k resultados ordenados por similaridade. Os scores são destacados por faixas: verde para >0,7, laranja para >0,5 e cinza para os demais. A Sidebar permite selecionar o modelo de embedding e o top-k.

Na aba Base Completa, todas as manifestações são exibidas e o usuário pode gerar a matriz de similaridade. Em Espaço Vetorial, PCA ou t-SNE reduz os embeddings para duas dimensões e os pontos são coloridos pelas categorias oficiais. Em Chunking, o usuário cola uma manifestação longa, escolhe uma das duas estratégias e visualiza os chunks e parte dos seus embeddings.

6. Modelos e cache

Foram disponibilizados dois modelos: paraphrase-multilingual-MiniLM-L12-v2 e BAAI/bge-small-pt-v1.5. O uso de modelos multilíngues ou específicos para português melhora a representação de textos brasileiros. O Streamlit utiliza st.cache_resource para manter o modelo carregado e st.cache_data para reutilizar embeddings, reduzindo o tempo de resposta.

7. Dificuldades e decisões técnicas

A principal dificuldade é equilibrar granularidade e contexto: textos longos exigem chunking, mas chunks pequenos podem separar informações que pertencem à mesma denúncia. Outra decisão é o limiar de duplicatas: 0.85 reduz candidatos irrelevantes, porém deve ser validado pelos pares conhecidos. PCA e t-SNE também são apenas projeções; proximidade visual não significa equivalência perfeita no espaço original.

8. Organização da equipe

Josenilton Cirne Ramalho Neto: preparação do corpus, limpeza, análise das representações e notebooks de comparação.
Pedro Henrique Alves Vieira do Nascimento: embeddings, detecção de duplicatas, chunking e análise das similaridades.
Igor Nunes Moneta: aplicação Streamlit, visualizações, integração, testes e organização do relatório/documentação.

9. Conclusão

O projeto integra representações esparsas e densas em um cenário de ouvidoria, mostrando as diferenças entre correspondência lexical e proximidade semântica. A solução também trata textos longos com chunking, identifica possíveis duplicatas e oferece uma interface interativa para exploração do corpus e dos embeddings.

10. Arquivos entregues

análise_comparativa.ipynb; deteccao_duplicatas.ipynb; chunking_manifestacoes.ipynb; app_ouvidoria.py; RELATORIO.pdf. O arquivo manifestacoes.csv e o README.md acompanham o projeto para facilitar reprodução e uso no GitHub.